

Validacao de Dados: RQ01 e RQ02

Laboratorio de Experimentacao de Software, Lab01 Sprint 02, Issue #21

Metodologia

Os dados foram coletados via consulta GraphQL a API do GitHub, cobrindo os 1000 repositorios com maior numero de estrelas. As colunas analisadas foram **age_days** (idade do repositorio em dias, a partir de createdAt, referente a RQ01) e **merged_pull_requests** (total de pull requests mescladas, usado como aproximacao de contribuicao externa, referente a RQ02). A validacao consiste em examinar distribuicao, valores ausentes e outliers antes de assumir os dados como confiaveis.

RQ01: Idade do repositorio

Pergunta: sistemas populares sao antigos? Metrica: idade em dias desde a criacao do repositorio.

Hipotese informal

Esperamos que repositorios populares sejam majoritariamente antigos, ja que acumular um numero alto de estrelas costuma exigir tempo de exposicao e uso continuo pela comunidade, tornando repositorios muito recentes uma minoria entre os mais populares.

Validacao dos dados

Estatistica	Valor
Valores ausentes	0 (0%)
Minimo	5 dias
Mediana	2829 dias (aproximadamente 7,7 anos)
P75	4147 dias (aproximadamente 11,4 anos)
Maximo	6703 dias (aproximadamente 18,4 anos)
Media	2798,8 dias

Achados

Os cinco repositorios mais antigos da amostra sao rails, git, jekyll, redis e jquery, todos criados entre 2008 e 2009, no inicio do GitHub, e ainda hoje entre os mais populares da plataforma - o que sustenta a ideia de que popularidade sustentada tende a se acumular ao longo de muitos anos.

Ainda assim, ha uma cauda de repositorios muito recentes: o caso mais extremo e deepseek-ai/deepseek-harness, com apenas 5 dias de existencia no momento da coleta, seguido por ponytail (67 dias), odysseus (79 dias), open-design (112 dias) e nature-skills (116 dias). Esses casos indicam que, especialmente em areas de grande interesse momentaneo (como IA), um repositorio pode entrar no top 1000 em questao de dias, contrariando a expectativa de acumulo gradual.

Observacao preliminar

A mediana de aproximadamente 7,7 anos sustenta a hipótese de que repositórios populares tendem a ser antigos. A existência de repositórios com poucos dias de vida já no top 1000, provavelmente ligados a picos de interesse (hype), será aprofundada na análise formal prevista para a sprint seguinte, junto com a discussão final entre hipótese e resultado.

RQ02: Contribuição externa

Pergunta: sistemas populares recebem muita contribuição externa? Métrica: total de pull requests mescladas.

Hipótese informal

Esperamos que repositórios populares recebam contribuição externa significativa, medida pelo número de pull requests mescladas, dado que maior visibilidade tende a atrair mais colaboradores dispostos a propor mudanças.

Validação dos dados

Estatística	Valor
Valores ausentes	0 (0%)
Mínimo	0
Mediana	768
P75	3413,5
Máximo	103307
Média	4233,4

Achados

20 repositórios (2% da amostra) apresentam zero pull requests mescladas. Esse valor não representa necessariamente ausência de contribuição externa: entre os casos estão `torvalds/linux` e `FFmpeg/FFmpeg`, projetos que historicamente aceitam contribuições por lista de e-mail em vez do fluxo de pull request do GitHub, além de repositórios com pouca atividade de desenvolvimento contínuo (por exemplo `chrislgarry/Apollo-11`, um repositório de arquivamento histórico). Nesses casos, o zero reflete uma limitação da métrica, e não a inexistência de colaboração.

No extremo oposto, `firstcontributions/first-contributions` aparece com 103307 pull requests mescladas, muito acima do segundo colocado (`llvm/llvm-project`, com 96939). Esse repositório existe especificamente como tutorial para ensinar iniciantes a abrir sua primeira pull request, e aceita deliberadamente um volume enorme de contribuições triviais - portanto não é comparável aos demais projetos de software da amostra e deve ser tratado como outlier atípico, não como um caso legítimo de alta colaboração técnica.

Observação preliminar

A mediana de 768 pull requests mescladas sustenta a hipótese de contribuição externa relevante entre repositórios populares. Os outliers em ambas as pontas - projetos que não usam o fluxo de PR do GitHub e o caso atípico do `first-contributions` - serão aprofundados na análise formal prevista para a sprint seguinte, junto com a discussão final entre hipótese e resultado.

Conclusao da validacao

Nenhuma das duas colunas apresentou valor ausente. A qualidade dos dados e considerada adequada para seguir com a analise das RQs, desde que as ressalvas identificadas sejam documentadas no relatorio final: repositorios que usam fluxos de contribuicao externos ao GitHub (como linux e FFmpeg) aparecem com zero pull requests mescladas sem que isso reflita ausencia real de colaboracao, e first-contributions e um outlier atipico (repositorio-tutorial, nao projeto de software real) que deve ser tratado com cuidado em analises agregadas de RQ02.

Dataset: data/raw/repositories.csv, 1000 repositorios, coletados via API GraphQL do GitHub.