

Validacao de Dados: RQ03 e RQ04

Laboratorio de Experimentacao de Software, Lab01 Sprint 02, Issue #22

Metodologia

Os dados foram coletados via consulta GraphQL a API do GitHub, cobrindo os 1000 repositorios com maior numero de estrelas. As colunas analisadas foram **releases** (total de releases publicadas, referente a RQ03) e **update_frequency_days** (dias desde o ultimo push, referente a RQ04). A validacao consiste em examinar distribuicao, valores ausentes e outliers antes de assumir os dados como confiaveis.

RQ03: Releases

Pergunta: sistemas populares lancam releases com frequencia? Metrica: total de releases.

Hipotese informal

Esperamos que repositorios populares lancem releases com frequencia regular, ja que projetos com muita visibilidade tendem a ter ciclos de desenvolvimento mais estruturados e cadencia de versionamento previsivel.

Validacao dos dados

Estatistica	Valor
Valores ausentes	0 (0%)
Minimo	0
Mediana	40
P75	149
Maximo	1000 (valor provavelmente limitado pela API)
Media	127,3

Achados

280 repositorios (28% da amostra) apresentam zero releases. Esse valor nao representa dado ausente, e sim uso real: grande parte desses repositorios sao listas de recursos ou material de referencia (por exemplo colecoes do tipo "awesome" e compilacoes de livros), que nao utilizam o recurso de Releases do GitHub por nao se tratarem de projetos de software com ciclo de versionamento.

Um segundo achado e a presenca de 21 repositorios (2,1% da amostra) com valor exatamente igual a 1000, entre eles langchain, next.js, llama.cpp, electron e storybook. Uma consulta

adicional a API REST do GitHub confirmou que o repositório electron possui na realidade 1981 releases, o que comprova um teto no campo totalCount retornado pela API GraphQL para esse tipo de conexão, e não um problema na nossa coleta.

Observação preliminar

A mediana de 40 releases sustenta parcialmente a hipótese, mas o alto percentual de repositórios com zero releases (28%) indica que a métrica não se aplica bem a toda a amostra. Esta é uma observação preliminar, com base apenas na validação dos dados, e será aprofundada na análise formal prevista para a sprint seguinte, junto com a discussão final entre hipótese e resultado.

RQ04: Frequência de atualização

Pergunta: sistemas populares são atualizados com frequência? Métrica: dias desde a última atualização.

Hipótese informal

Esperamos que repositórios populares sejam atualizados com frequência alta, dado que atraem mais colaboradores e exigem manutenção constante para sustentar a base de usuários.

Validação dos dados

Estatística	Valor
Valores ausentes	0 (0%)
Mínimo	0 dias
Mediana	2 dias
P75	51 dias
Máximo	2447 dias (aproximadamente 6,7 anos)
Média	113,3 dias

Achados

331 repositórios (33,1% da amostra) foram atualizados no próprio dia da coleta, e a mediana geral é de apenas 2 dias desde o último push. Isso indica manutenção muito ativa na maioria dos repositórios populares.

Ainda assim, 114 repositórios (11,4% da amostra) não recebem push há mais de um ano. Os cinco casos mais extremos são: deeplearningbook chinês (2447 dias), edex ui (1761 dias), libpku (1683 dias), brackets (1525 dias) e Deep Learning Papers Reading Roadmap (1357 dias). A maior parte desses casos é material de referência estático (livros, listas de recursos), que permanece popular pelo conteúdo mesmo sem manutenção contínua.

Observação preliminar

A mediana de 2 dias sustenta fortemente a hipótese. A cauda de repositórios parados há mais de um ano, em geral material de referência estático, será investigada com mais detalhe na análise formal prevista para a sprint seguinte, junto com a discussão final entre hipótese e resultado.

Conclusão da validação

Nenhuma das duas colunas apresentou valor ausente. A qualidade dos dados é considerada adequada para seguir com a análise das RQs, desde que as duas ressalvas identificadas sejam documentadas no relatório final: o teto aparente de 1000 no campo releases, e a presença legítima de repositórios com zero releases por não usarem esse recurso do GitHub.

Dataset: data/raw/repositories.csv, 1000 repositórios, coletados via API GraphQL do GitHub.