

Validação de Dados: RQ05 e RQ06

Laboratório de Experimentação de Software, Lab01 Sprint 02, Issue #23

Metodologia

Os dados foram coletados via consulta GraphQL à API do GitHub, cobrindo os 1000 repositórios com maior número de estrelas. As colunas analisadas foram `primary_language`, linguagem primária de cada repositório, referente à RQ05, e `closed_issues_ratio`, razão entre issues fechadas e total de issues, referente à RQ06. A validação consiste em examinar distribuição, valores ausentes e outliers antes de assumir os dados como confiáveis.

RQ05: Linguagem primária

Pergunta: sistemas populares são escritos nas linguagens mais populares? Métrica: linguagem primária de cada repositório.

Hipótese informal

Esperamos que a maioria dos repositórios populares esteja concentrada nas linguagens de propósito geral mais usadas do mercado, ex.: JavaScript/TypeScript, Python, Java, já que essas linguagens têm o maior número de desenvolvedores e ecossistemas mais maduros para projetos open-source de grande escala.

Validação dos dados

Estatística	Valor
Valores ausentes	87 (8,7%)
Linguagens distintas	43
Linguagem mais frequente	Python, 22,9%
Top 3 (Python, TypeScript, JavaScript)	51,3% acumulado

Achados

8,7% dos repositórios (87) não têm linguagem primária definida. Esse valor não representa erro de coleta: são repositórios sem código-fonte majoritário, cujo conteúdo é majoritariamente Markdown, então o GitHub não atribui linguagem primária de programação a eles.

Entre os repositórios com linguagem identificada, Python (22,9%), TypeScript (17,4%) e JavaScript (11,0%) concentram 51,3% da amostra.

Observação preliminar

A concentração em Python, TypeScript e JavaScript sustenta a hipótese informalmente, já que são linguagens amplamente reconhecidas como populares no mercado.

RQ06: Percentual de issues fechadas

Pergunta: sistemas populares possuem um alto percentual de issues fechadas? Métrica: razão entre issues fechadas e total de issues.

Hipótese informal

Esperamos que repositórios populares tenham uma alta taxa de issues fechadas, já que a visibilidade atrai mantenedores e contribuidores que respondem e resolvem problemas relatados com mais agilidade.

Validação dos dados

Estatística	Valor
Valores ausentes	43 (4,3%)
Mínimo	7,69%
Mediana	87,51%
P75	96,77%
Máximo	100,00%
Média	80,23%

Achados

4,3% dos repositórios (43) não têm valor calculado. Esse valor não representa erro de coleta: correspondem a repositórios com zero issues registradas no total, alguns por serem listas sem rastreamento ativo, e um caso notável é o linux, que tem o rastreador de Issues desligado no GitHub porque o kernel usa lista de e-mails como canal oficial de bugs.

Além disso, 26 repositórios (2,6%) têm razão de exatamente 100%. Confirmamos numa consulta separada que não é artefato de amostra pequena, o nilbuild/developer-roadmap, por exemplo, tem 3184 issues no total, todas fechadas, o que sugere bots de triagem automática ou política agressiva de fechamento.

Observação preliminar

A mediana de 87,51% sustenta fortemente a hipótese: a maioria dos repositórios populares mantém quase todas as issues fechadas. O mínimo de 7,69%, porém, mostra que existe uma cauda de projetos com baixa taxa de resolução, que será investigada com mais detalhe na análise formal prevista para a sprint seguinte, junto com a discussão final entre hipótese e resultado.

Conclusão da validação

Ambas as colunas apresentaram valores ausentes explicados por características legítimas dos repositórios, ausência de código-fonte majoritário ou de rastreador de issues ativo, não por falha

na coleta. A qualidade dos dados é considerada adequada para seguir com a análise das RQs, desde que as ressalvas identificadas sejam documentadas no relatório final, a ausência de linguagem primária em repositórios sem código-fonte, a desativação do rastreador de issues em projetos como o linux, e a definição pendente da fonte de referência para linguagens mais populares exigida pela RQ05.

Dataset: data/raw/repositories.csv, 1000 repositórios, coletados via API GraphQL do GitHub.